

**Implementación de un dashboard analítico y análisis exploratorio avanzado del abandono
de clientes en telecomunicaciones**

Bonny Darhyll Brayan Galindo Santos

Andrés Alberto López Herrera

Camilo José Rodríguez Ayubi

Especialización en Inteligencia Artificial

Corporación Unificada Nacional de Educación Superior (CUN)

Programación para Analítica de Datos e IA · ACA 2

Docente: Hamilton Rivera

Septiembre de 2026

Enlaces del proyecto

Aplicación publicada (Streamlit Community Cloud): <https://aca2-telco-churn-cun.streamlit.app>

Repositorio del proyecto (GitHub): <https://github.com/bonnymusic77-web/aca2-dashboard-telco-churn>

Notebook en Google Colab: https://colab.research.google.com/github/bonnymusic77-web/aca2-dashboard-telco-churn/blob/main/ACA2_Dashboard_EDA_Telco_Churn.ipynb

Video de sustentación: [pegar enlace de YouTube o Google Drive]

Tabla de contenido

Introducción.....	3
Objetivos y propuesta.....	3
Datos y preparación.....	4
Descripción del conjunto de datos.....	4
Limpieza y preprocesamiento.....	4
Análisis exploratorio de datos.....	5
Variable objetivo y estadística descriptiva.....	5
Distribuciones y normalidad.....	6
Tasa de abandono por variables categóricas.....	7
Pruebas de hipótesis.....	9
Correlaciones.....	11
Segmentos de mayor riesgo.....	12
Arquitectura del dashboard.....	14
Estructura modular.....	14
Librerías utilizadas y justificación.....	15
Funcionalidades de la aplicación.....	16
Verificación y publicación.....	19
Conclusiones.....	20
Referencias.....	22

Implementación de un dashboard analítico y análisis exploratorio avanzado del abandono de clientes en telecomunicaciones

Introducción

En empresas que venden servicios por suscripción, como las de telecomunicaciones, la pérdida de clientes (*churn*) golpea directamente el ingreso recurrente, y retener a un cliente suele resultar más económico que conseguir uno nuevo (Verbeke et al., 2012). Saber quiénes se van y por qué es, entonces, una pregunta de negocio antes que técnica.

En el ACA 1 hicimos un primer análisis exploratorio de la base *Telco Customer Churn* (IBM, s. f.). Este reporte documenta la segunda fase del proyecto: un proceso automatizado de limpieza, un análisis exploratorio con pruebas de hipótesis y tamaños de efecto, y un dashboard web desarrollado en Streamlit que permite explorar los resultados sin escribir código. El detalle del código está en el notebook de Google Colab que acompaña este documento.

Objetivos y propuesta

Pregunta de negocio. ¿Qué características de los clientes y de sus contratos se relacionan con el abandono, y en qué segmentos se concentra el ingreso que la empresa pierde?

Objetivo general. Construir un dashboard interactivo en Python que permita explorar el abandono de clientes y obtener hallazgos respaldados por evidencia estadística.

Objetivos específicos.

1. Automatizar la limpieza y transformación del archivo crudo en un proceso reutilizable que deje registro de cada paso.
2. Profundizar el análisis exploratorio con pruebas de hipótesis, tamaños de efecto y correlaciones.
3. Desarrollar una aplicación web con filtros dinámicos, gráficos interactivos y una sección de análisis automático.
4. Traducir los resultados en recomendaciones de retención para el negocio.

Propuesta. El código se organizó en cuatro módulos de Python: `procesamiento.py` (carga y limpieza), `analisis.py` (estadística), `graficos.py` (visualizaciones interactivas) y

app.py (interfaz). El notebook genera esos archivos, los importa para hacer el análisis y prueba la aplicación antes de publicarla. De esta forma, las cifras del reporte, del notebook y del dashboard salen exactamente de las mismas funciones.

Datos y preparación

Descripción del conjunto de datos

La base contiene 7.043 clientes de una compañía de telecomunicaciones ficticia creada por IBM y 21 variables. La variable objetivo, Churn, indica si el cliente se retiró en el último mes. Las demás describen su perfil, los servicios que tiene contratados y las condiciones de su cuenta (Tabla 1).

Tabla 1

Variables del conjunto de datos Telco Customer Churn

Grupo	Variables	Tipo
Identificación	customerID	Texto
Objetivo	Churn (abandono en el último mes)	Binaria
Perfil	gender, SeniorCitizen, Partner, Dependents	Categóricas
Servicios	PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies	Categóricas
Cuenta	Contract, PaperlessBilling, PaymentMethod	Categóricas
Cuenta	tenure (meses), MonthlyCharges y TotalCharges (USD)	Numéricas

Nota. Elaboración propia con base en IBM (s. f.).

Limpieza y preprocesamiento

El diagnóstico inicial no mostró valores nulos, pero TotalCharges venía como texto y tenía 11 celdas con un espacio en blanco, un faltante que la función `isna()` de pandas no detecta. Los 11 registros correspondían a clientes con cero meses de antigüedad, casi todos con contrato a dos años, que aún no habían recibido su primera factura. Eliminarlos implicaba perder clientes válidos e imputar la mediana (cerca de USD 1.400) les inventaba un historial, así que se les asignó un cargo acumulado de 0.

Ninguna variable numérica presentó atípicos según la regla de Tukey (1977). El cargo total difiere en mediana apenas 2 % del producto antigüedad $\times$ cargo mensual y solo 27 clientes superan una diferencia del 25 %, lo que se explica por cambios de plan. Por eso los valores extremos se conservaron. La Tabla 2 resume el proceso.

Tabla 2

Pasos del proceso de limpieza y registros afectados

Paso	Decisión	Registros
Texto y tipos	Recortar espacios, convertir textos vacíos en nulos y TotalCharges a numérico	11
Duplicados	Eliminar filas y customerID repetidos	0
Dominios	Categorías no válidas y cargos negativos pasan a nulos	0
Nulos	TotalCharges con tenure = 0 $\rightarrow$ 0; numéricas $\rightarrow$ mediana; categóricas $\rightarrow$ moda	11
Atípicos	Regla IQR con opción de conservar, recortar o eliminar; se conservan	0
Transformación	Categorías en español; variables abandono, grupo_antigüedad, num_servicios y pago_automatico	7.043

Nota. Las funciones de validación de dominios e imputación no afectaron registros en el archivo original, pero se probaron con una copia a la que se le agregaron errores a propósito (duplicados, una categoría mal escrita, un cargo negativo y un cliente sin etiqueta); el proceso los corrigió todos y terminó sin nulos.

El resultado final conserva los 7.043 clientes, sin nulos ni duplicados, con 25 columnas. Las validaciones al final de la función `preparar_datos()` detienen la ejecución si alguna de estas condiciones no se cumple.

Análisis exploratorio de datos

En todas las pruebas se usó un nivel de significancia $\alpha = 0,05$. Con más de siete mil registros casi cualquier diferencia resulta significativa, por lo que además del valor p se reporta el tamaño del efecto y se interpreta con los umbrales de Cohen (1988).

Variable objetivo y estadística descriptiva

De los 7.043 clientes, 1.869 abandonaron la compañía, una tasa de 26,5 %. Ese grupo facturaba USD 139.131 al mes, el 30,5 % del ingreso total: su peso en ingreso supera su peso en clientes porque pagan más en promedio (USD 74,44 frente a USD 61,27). La Tabla 3 muestra

que quienes abandonan llevan mucho menos tiempo en la empresa y tienen cargos mensuales más altos.

Tabla 3

Estadísticos descriptivos de las variables numéricas

Variable	Media	Mediana	Desv. est.	Asimetría	Mediana permanece	Mediana abandona
Antigüedad (meses)	32,37	29,00	24,56	0,24	38,00	10,00
Cargo mensual (USD)	64,76	70,35	30,09	-0,22	64,43	79,65
Cargo total (USD)	2.279,73	1.394,55	2.266,79	0,96	1.679,52	703,55


Nota. n = 7.043 (5.174 permanecen y 1.869 abandonan).

Distribuciones y normalidad

La prueba de D'Agostino y Pearson (1973) rechazó la normalidad en las tres variables numéricas ($p < 0,001$), y los gráficos confirman que no es un efecto del tamaño de muestra (Figura 1). La antigüedad tiene forma de U, con 613 clientes de un mes y 362 de 72 meses; el cargo mensual es bimodal, con un pico cerca de USD 20 que corresponde a clientes sin internet; el cargo total tiene cola larga a la derecha. Por esta razón, las comparaciones entre grupos se hicieron con pruebas no paramétricas y las correlaciones se leyeron con el coeficiente de Spearman.

Figura 1

Distribución de las variables numéricas según abandono



Nota. Los histogramas muestran el porcentaje de clientes dentro de cada grupo. Elaboración propia con datos de IBM (s. f.).


Los histogramas dejan ver el patrón central del análisis: la mayoría de clientes que se van lo hacen en los primeros meses y con cargos mensuales entre USD 70 y USD 105.

Tasa de abandono por variables categóricas

El tipo de contrato marca la diferencia más grande: 42,7 % de abandono en contratos mes a mes, 11,3 % en contratos de un año y 2,8 % en los de dos años (Figura 2). El cheque electrónico llega a 45,3 %, mientras los medios de pago automáticos se quedan entre 15 % y 17 %. Por antigüedad, el 47,4 % de los clientes con menos de un año se retira, frente a 9,5 % de quienes llevan más de cuatro años.

Figura 2

Tasa de abandono por variables de contrato, facturación y permanencia




Nota. Las barras de error representan el intervalo de confianza del 95 % de Wilson (1927); la línea vertical marca la tasa global de 26,5 %.

En servicios, la fibra óptica registra 41,9 % de abandono, más del doble que DSL (19,0 %). Quienes no tienen seguridad en línea o soporte técnico se retiran cerca de 42 % de las veces, frente a 15 % de quienes sí los tienen (Figura 3). El *streaming* apenas cambia la tasa y la telefonía no la cambia. En el perfil, los adultos mayores abandonan más (41,7 % frente a 23,6 %), igual que quienes no tienen pareja (33,0 %) o dependientes (31,3 %); el género no marca diferencia (26,9 % frente a 26,2 %).

Figura 3

Tasa de abandono según los servicios contratados



Nota. Las barras de error representan el intervalo de confianza del 95 %; la línea vertical marca la tasa global. Las gráficas de protección de equipos, películas por streaming y múltiples líneas están en el notebook.

Pruebas de hipótesis

Para las variables categóricas se aplicó la prueba chi-cuadrado de independencia (H_0 : la variable y el abandono son independientes). Como se hicieron 16 pruebas, los valores p se ajustaron con la corrección de Bonferroni y la fuerza de la asociación se midió con la V de Cramér (1946). En todas las tablas de contingencia el 100 % de las frecuencias esperadas fue mayor o igual a 5, por lo que el supuesto de la prueba se cumple.

Tabla 4*Prueba chi-cuadrado de independencia entre cada variable categórica y el abandono*

Variable	χ^2	gl	p ajustado	V de Cramér	Efecto
Tipo de contrato	1.184,60	2	< 0,001	0,410	Mediano
Seguridad en línea	850,00	2	< 0,001	0,347	Mediano
Soporte técnico	828,20	2	< 0,001	0,343	Mediano
Servicio de internet	732,31	2	< 0,001	0,322	Mediano
Método de pago	648,14	3	< 0,001	0,303	Mediano
Respaldo en línea	601,81	2	< 0,001	0,292	Pequeño
Protección de equipos	558,42	2	< 0,001	0,282	Pequeño
TV por streaming	374,20	2	< 0,001	0,231	Pequeño
Películas por streaming	375,66	2	< 0,001	0,231	Pequeño
Factura electrónica	259,16	1	< 0,001	0,192	Pequeño
Tiene dependientes	189,94	1	< 0,001	0,164	Pequeño
Adulto mayor	160,35	1	< 0,001	0,151	Pequeño
Tiene pareja	159,41	1	< 0,001	0,150	Pequeño
Múltiples líneas	11,33	2	0,055	0,040	Despreciable
Servicio telefónico	1,00	1	1,000	0,012	Despreciable
Género	0,52	1	1,000	0,009	Despreciable

Nota. p ajustado con corrección de Bonferroni (16 pruebas). Tamaño del efecto: 0,1 pequeño, 0,3 mediano y 0,5 grande (Cohen, 1988).

Trece de las dieciséis variables tienen asociación significativa con el abandono. Las más fuertes, todas de efecto mediano, son tipo de contrato, seguridad en línea, soporte técnico, servicio de internet y método de pago. Múltiples líneas deja de ser significativa al corregir por comparaciones múltiples, y género y servicio telefónico no muestran asociación.

Para las variables numéricas se usó la prueba U de Mann y Whitney (1947), con la correlación biserial por rangos como tamaño del efecto (Tabla 5). La antigüedad es la variable con mayor efecto: quienes abandonan tienen una mediana de 10 meses frente a 38 de quienes permanecen. El cargo mensual va en sentido contrario, con un efecto pequeño: los clientes que se retiran pagan más cada mes.

Tabla 5*Prueba U de Mann-Whitney entre clientes que permanecen y clientes que abandonan*


Variable	Mediana permanece	Mediana abandona	U	p	r	Efecto
Antigüedad (meses)	38,00	10,00	7.154.668	< 0,001	-0,48	Mediano
Cargo mensual (USD)	64,43	79,65	3.667.080	< 0,001	0,24	Pequeño
Cargo total (USD)	1.679,52	703,55	6.288.982	< 0,001	-0,30	Mediano

Nota. r negativo indica valores menores en quienes abandonan.

Por último, la prueba de Kruskal y Wallis (1952) mostró que la antigüedad cambia mucho según el tipo de contrato ($\eta^2H = 0,45$, efecto grande), es decir, contrato y antigüedad cuentan en parte la misma historia. El cargo mensual depende sobre todo del tipo de internet ($\eta^2H = 0,79$), con la fibra óptica como el servicio más caro (mediana de USD 91,68 frente a USD 56,15 en DSL), pero casi no cambia con el contrato ($\eta^2H = 0,003$). Los contratos largos no son más baratos, lo que descarta el precio como explicación de su baja tasa de abandono. El tamaño del efecto η^2H se calculó según Tomczak y Tomczak (2014).

Correlaciones

Las matrices de Pearson y Spearman dan resultados parecidos (Figura 4). La antigüedad y el cargo total tienen una correlación de 0,89, lo que indica que el cargo total es casi una combinación de antigüedad y tarifa; en un modelo predictivo convendría no usar ambas. Frente al abandono, la antigüedad es la variable numérica más relacionada ($\rho = -0,37$), seguida del cargo total (-0,23) y el cargo mensual (0,18).

Figura 4*Matrices de correlación de Pearson y Spearman*

Nota. Abandono codificado como 0 (permanece) y 1 (abandona). N.º servicios corresponde a la cantidad de servicios adicionales contratados.


Entre variables categóricas, seguridad en línea y soporte técnico tienen una V de Cramér de 0,72 con el tipo de internet, en parte porque comparten la categoría «sin servicio de internet». Para descartar que su efecto fuera solo un reflejo del tipo de conexión, se revisó la tasa dentro de los clientes de fibra óptica: sin soporte técnico abandona el 49,4 % y con soporte el 22,6 %; sin seguridad en línea el 49,4 % y con ella el 21,8 %. El efecto protector se mantiene.

Segmentos de mayor riesgo

Al cruzar variables aparecen los grupos críticos (Figura 5). La combinación de contrato mes a mes y fibra óptica reúne 2.128 clientes, el 30,2 % de la base, con una tasa de abandono de 54,6 %; si además pagan con cheque electrónico, la tasa sube a 60,4 %. En el otro extremo, los contratos a dos años con DSL apenas llegan a 1,9 %. El contrato pesa incluso con los años: un cliente mes a mes con más de cuatro años de antigüedad todavía abandona 26,0 %.

Figura 5

Tasa de abandono al cruzar tipo de contrato con servicio de internet y con grupo de antigüedad




Nota. Cada celda muestra la tasa de abandono y el número de clientes del segmento.

La Figura 6 muestra que en los primeros seis meses la tasa supera el 50 % y baja del promedio alrededor del segundo año. Los clientes con menos de un año son el 55,5 % de todos los abandonos. En ingreso, los contratos mes a mes explican el 86,9 % de la facturación mensual perdida y la fibra óptica el 82,2 %. Todas las diferencias de estos segmentos frente a la tasa global fueron significativas en la prueba binomial ($p < 0,001$).

Figura 6

Tasa de abandono por tramos de antigüedad e ingreso mensual perdido por tipo de contrato



Nota. La banda sombreada corresponde al intervalo de confianza del 95 %.


Arquitectura del dashboard

Estructura modular

La aplicación separa datos, análisis, visualización e interfaz en módulos independientes (Figura 7). Cada vez que el usuario cambia un filtro, Streamlit vuelve a ejecutar `app.py`: toma los valores guardados en el estado de la sesión, filtra la base y recalcula indicadores, gráficos y pruebas. La carga y limpieza del CSV se guarda en caché con `@st.cache_data`, de modo que solo se procesa una vez.

Figura 7

Arquitectura de la solución



Nota. Elaboración propia.

Librerías utilizadas y justificación

Tabla 6

Librerías del proyecto y razones de su elección

Librería	Uso	Justificación
Streamlit	Interfaz web, filtros, pestañas, indicadores y caché	Permite construir la aplicación solo con Python, sin HTML ni callbacks. Frente a Dash requiere menos código para un tablero de este tamaño y se publica gratis en Streamlit Community Cloud
Plotly	Gráficos interactivos	Ofrece zoom, hover y selección por caja o lazo sin programar JavaScript; Streamlit devuelve a Python los puntos seleccionados
pandas y NumPy	Manipulación y filtrado de datos	Estándar para datos tabulares (Harris et al., 2020; McKinney, 2010)
SciPy	Pruebas estadísticas	Implementa chi-cuadrado, Mann-Whitney, Kruskal-Wallis, binomial y D'Agostino-Pearson (Virtanen et al., 2020)
Matplotlib y Seaborn	Gráficos estáticos del notebook y del reporte	Generan imágenes reproducibles que se ven igual en Colab y en PDF (Hunter, 2007; Waskom, 2021)

Funcionalidades de la aplicación

El encabezado presenta el nombre del proyecto, una descripción breve, los integrantes y la universidad. Debajo, cinco indicadores muestran clientes, tasa de abandono, clientes perdidos, ingreso en riesgo y antigüedad media, con su diferencia frente a la base total (Figura 8). La barra lateral agrupa los filtros dinámicos: tipo de contrato, servicio de internet, método de pago, soporte técnico, adulto mayor y los rangos de antigüedad y cargo mensual, con un botón para restablecerlos. Todos los elementos de la página se recalculan con la selección.

Figura 8

Pestaña Resumen del dashboard




Nota. Captura de la aplicación sin filtros aplicados.

El contenido se organiza en seis pestañas:

- **Resumen:** tasa de abandono por contrato y por método de pago con intervalos de confianza, curva según antigüedad e ingreso perdido por tipo de internet.
- **Exploración:** permite elegir cualquier variable y muestra su distribución o su tasa por categoría junto con la prueba estadística correspondiente. Incluye un gráfico de dispersión en el que el usuario selecciona clientes con caja o lazo y obtiene los indicadores de ese grupo (Figura 9).
- **Segmentos:** mapa de calor para cruzar dos variables a elección y ranking de los segmentos con mayor abandono, con un tamaño mínimo ajustable para evitar grupos pequeños.
- **Análisis automático:** redacta hallazgos en texto y recalcula chi-cuadrado, Mann-Whitney, correlaciones y descriptivos para la selección actual (Figura 10). Si el filtro deja menos de 30 clientes o menos de 10 casos en algún grupo, avisa en lugar de mostrar resultados poco confiables.
- **Vista previa:** primeros registros, estructura del dataset (tipo de variable, datos no nulos y valores únicos), resumen estadístico y descarga de la selección en CSV.
- **Calidad de datos:** bitácora de limpieza, diagnóstico del archivo crudo y revisión de atípicos.

Figura 9*Selección interactiva de clientes en la pestaña Exploración*

Arrastre sobre el gráfico (caja o lazo) para analizar un grupo; doble clic para quitar la selección.



Nota. Al seleccionar con caja a los clientes con menos de un año y cargos superiores a USD 80, la aplicación calcula una tasa de abandono de 73,2 % para ese grupo.

Figura 10

Pestaña Análisis automático con filtros de contrato mes a mes y fibra óptica



Nota. Los indicadores y hallazgos corresponden únicamente a los 2.128 clientes filtrados. Debajo de los hallazgos, la pestaña muestra la V de Cramér, la correlación de Spearman y las tablas de las pruebas.

Verificación y publicación

Antes de publicar, la aplicación se probó con AppTest, la herramienta de pruebas de Streamlit: se ejecutó sin errores con la base completa, con filtros combinados y con selecciones casi vacías. Los módulos de limpieza, análisis y gráficos también se probaron con pandas 2.2 y 3.0, para asegurar que funcionen tanto en Google Colab como en Streamlit Community Cloud, donde la aplicación quedó publicada desde el repositorio de GitHub del proyecto y está disponible en <https://aca2-telco-churn-cun.streamlit.app>.

Para mostrar la aplicación en vivo desde Colab, el notebook incluye además una celda opcional con Ngrok, que crea un túnel hacia una URL pública temporal. Cada integrante usa su propio Authtoken, guardado en los Secretos de Colab para que no quede escrito en el archivo. Como ese enlace deja de funcionar al cerrar la sesión, el enlace que se entrega es el de Streamlit Community Cloud.

Conclusiones

1. **El tipo de contrato es la principal palanca de retención.** Los clientes mes a mes abandonan 42,7 % frente a 2,8 % en contratos de dos años y concentran el 86,9 % del ingreso perdido. Como el cargo mensual no cambia con el contrato, la diferencia no se explica por precio. Incentivar el paso a planes anuales durante los primeros meses es la acción con mayor impacto potencial.
2. **El primer año es la ventana crítica.** Casi la mitad de los clientes con menos de doce meses se retira y ese grupo aporta el 55,5 % de todos los abandonos. Un programa de acompañamiento en los primeros seis meses atacaría el tramo donde la tasa supera el 50 %.
3. **La fibra óptica pierde clientes de alto valor.** Tiene 41,9 % de abandono, es el servicio más caro y explica el 82,2 % de la facturación perdida. La base no incluye satisfacción ni incidencias técnicas, así que la causa no puede confirmarse; conviene revisar precio y calidad de este servicio.
4. **Soporte técnico y seguridad en línea funcionan como retención.** Entre clientes de fibra, contar con soporte técnico reduce la tasa de 49,4 % a 22,6 %. Incluirlos sin costo o con descuento al inicio podría bajar el riesgo del segmento más crítico (mes a mes con fibra, 54,6 %).
5. **El medio de pago sirve como alerta temprana.** Con cheque electrónico abandona el 45,3 %, frente a 15 % a 17 % con pago automático. Promover el débito automático es una medida de bajo costo, aunque la asociación no demuestra que cambiar el medio de pago evite el retiro.

En cuanto al proyecto, el proceso de limpieza deja la base lista en un solo llamado, valida su resultado y responde bien ante datos con errores. El dashboard permite que un usuario sin conocimientos de programación llegue a estos mismos hallazgos con los filtros, y la sección de análisis automático recalcula las pruebas para cualquier segmento.

Los datos corresponden a un solo corte en el tiempo, por lo que las relaciones encontradas son asociaciones y no efectos causales. Tampoco hay variables de satisfacción, reclamos o calidad de la señal, que ayudarían a explicar el abandono en fibra óptica. Como trabajo futuro, estos hallazgos sirven de base para un modelo predictivo que asigne a cada cliente una probabilidad de retiro.

Referencias

- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.^a ed.). Lawrence Erlbaum Associates.
- Cramér, H. (1946). *Mathematical methods of statistics*. Princeton University Press.
- D'Agostino, R. B., & Pearson, E. S. (1973). Tests for departure from normality. Empirical results for the distributions of b_2 and $\sqrt{b_1}$. *Biometrika*, 60(3), 613–622.
<https://doi.org/10.1093/biomet/60.3.613>
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362.
<https://doi.org/10.1038/s41586-020-2649-2>
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- IBM. (s. f.). *Telco Customer Churn* [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
- Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621.
<https://doi.org/10.1080/01621459.1952.10483441>
- Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1), 50–60.
<https://doi.org/10.1214/aoms/1177730491>
- McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt & J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61).
<https://doi.org/10.25080/Majora-92bf1922-00a>
- Plotly Technologies Inc. (2015). *Collaborative data science*. <https://plot.ly>

- Streamlit. (s. f.). *Streamlit documentation*. Recuperado el 17 de septiembre de 2026, de <https://docs.streamlit.io>
- Tomczak, M., & Tomczak, E. (2014). The need to report effect size estimates revisited. An overview of some recommended measures of effect size. *Trends in Sport Sciences*, 1(21), 19–25.
- Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.
- Verbeke, W., Dejaeger, K., Martens, D., Hur, J., & Baesens, B. (2012). New insights into churn prediction in the telecommunication sector: A profit driven data mining approach. *European Journal of Operational Research*, 218(1), 211–229. <https://doi.org/10.1016/j.ejor.2011.09.031>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... van Mulbregt, P. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209–212. <https://doi.org/10.1080/01621459.1927.10502953>